

銀行顧客データを用いた定期預金 ・ NISA開設予測モデル構築





機械学習による提案方針最適化シミュレーション

プロジェクト背景と目的

- ❗ 課題：銀行営業現場では顧客ごとの提案判断が属人的
- 🎯 目的：データに基づく「提案最適化」の実現
- 🗄️ データソース：SIGNATE公開データを活用



データと分析手法

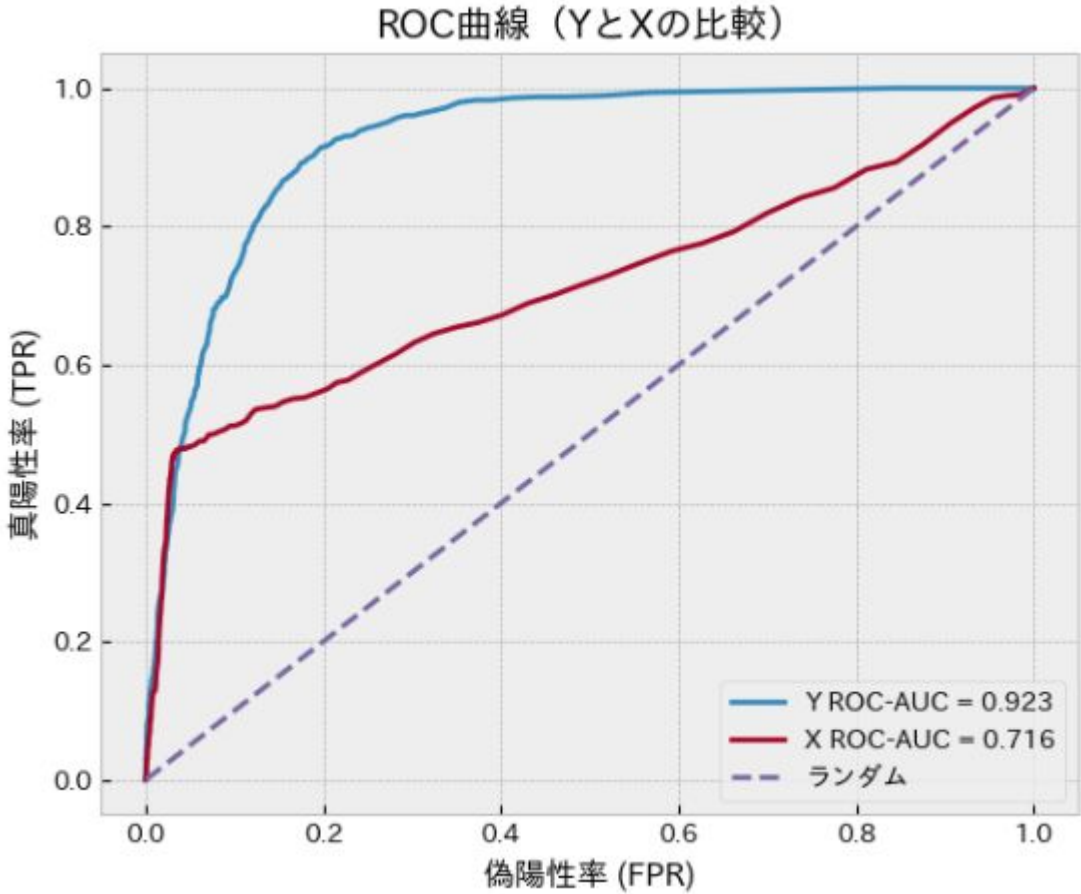
-  データ件数：27,128件（SIGNATE銀行顧客データ）
-  NISA開設データ：仮想付与（ペルソナ設定に基づく）
-  機械学習：RandomForest + CalibratedClassifierCV
-  データ分割：Train 60% / Validation 20% / Test 20%




予測モデルの性能評価


- 定期預金モデルは高精度・安定
- NISAモデルは中精度だが有用


評価指標	定期預金(Y)	NISA(X)
ROC-AUC	0.92	0.72
PR-AUC	0.59	0.42
Brier Score	0.07	0.08



提案方針決定ロジック

 各顧客にY確率とX確率を算出

 高い方を提案するPolicy方式

 比較：常にY、常にX、ランダム選択



提案最適化による成果

19.6%

Policy成功率

11.7%


Baseline成功率

+7.9pt

改善幅（約1.7倍）

- ✓ 正しい提案選択率: **87.9%**
- ★ Top1000顧客成功率: **61.6%**

方針の有効性（成功率の比較）




顧客セグメント別の確率分布

≡ 確率差を10%刻みに区分し顧客分布を可視化

👥 大半は僅差／明確なY/X優先層も存在

🔍 セグメント別の特性理解が可能



成果と今後の展望

🔧 成果

- ✓ 提案成功率が約1.7倍向上
- ✓ 確率較正により高信頼予測
- ✓ データドリブンな営業基盤

💡 今後の展望

- 特徴量拡充（残高、年収、行動履歴等）
- XGBoost等の比較
- SHAP値で説明性向上